

基于 LoRA 的离散数学课程助教模型：数据构建、参数高效微调与实验分析

- 项目组：Group 6
- 成员：冷木卡、杨宇晖、王俞天涯
- 分工：冷木卡负责 QA 数据生成，王俞天涯负责 QA 数据过滤，杨宇晖负责模型训练与参数实验。

摘要

本项目面向离散数学课程教学场景，构建一个能够正确回答课程问题，并以简洁、准确、适合学生理解的方式组织答案的课程助教模型。项目以南方科技大学 CS201 离散数学课程十章 Markdown 讲义为知识来源，调用 DeepSeek-V4-Flash 生成中文问答对，随后依次执行长度约束、基于 BGE-base-zh-v1.5 的问答相关性与问题去重、基于 Qwen-3.6-27B 的质量评分，以及五倍语义保持式数据增强。在模型侧，项目比较了 Qwen3.5-0.8B、2B 与 4B，不同 LoRA Rank、部分层微调和 Dropout 设置，并最终选择 Qwen3.5-2B 与全层 LoRA。最终实验采用 $r = 4$ 、 $\alpha = 8$ 、 $\text{dropout} = 0.5$ ，仅训练 1,253,376 个参数，占 1,883,078,464 个总参数的 0.0666%。在 48,075 条增强 QA 上训练 15 轮后，固定测试集损失由第 1 轮的 0.902961 单调下降至第 15 轮的 0.840197，相应困惑度由 2.466896 降至 2.316823。结果表明，低秩适配、语义增强和较强 Dropout 的组合能够以较低训练成本改善领域回答风格与固定测试集拟合；但当前实验仍缺少独立人工评分和未增强、未同源测试集上的严格基线，因此关于知识正确性的结论应保持审慎。

1. 实验背景与目标

1.1 背景

通用大语言模型通常能够解释基础离散数学概念，但其回答可能冗长、风格不稳定，或未充分贴合具体课程讲义。课程助教系统不仅需要生成语言通顺的文本，还应满足以下领域约束：

- **正确性**：数学定义、定理、公式和推导应正确。
- **课程一致性**：回答应覆盖 CS201 讲义中的逻辑与证明、集合与函数、算法复杂度、数论与密码学、归纳与递归、计数、关系、图与树及复习内容。
- **教学可用性**：表述应清晰、适合学生理解，并给出必要的推导过程。
- **风格约束**：回答应简洁、准确，避免无关铺垫和冗余展开。
- **训练经济性**：在有限算力下，通过参数高效微调完成领域适配。

1.2 实验目标

本项目的目标包括：

1. 从十章离散数学讲义自动构建覆盖多种认知层次的中文 QA 数据集。
2. 建立可解释的多阶段数据清洗流程，降低超长文本、答非所问、语义重复和低质量答案的比例。
3. 比较基础模型规模、LoRA Rank、微调层位置、Dropout 和数据增强对表达能力与泛化性的

影响。

4. 在训练成本、过拟合风险和回答质量之间选择最终配置。
5. 通过固定测试集损失和训练前后案例评估微调效果。

2. 项目架构

2.1 模型架构解析

最终训练采用 Qwen3.5-2B。该模型并非由同一种注意力层重复堆叠，而是采用 Linear Attention 与全量 Self-Attention 周期性交替的特殊混合注意力架构。文本主干共有 24 层，由 6 个结构相同的 Mixed Attention Block 串联组成，每个 Block 的层序列为：

```
输入
-> [Linear Attention
    -> Linear Attention
    -> Linear Attention
    -> Full Self-Attention] × 6
-> 输出
```

若将第 i 个 Mixed Attention Block 表示为 $\mathcal{B}_i$ ，则其结构可写为：

$$\mathcal{B}_i = [\text{LA}_{4i-3}, \text{LA}_{4i-2}, \text{LA}_{4i-1}, \text{SA}_{4i}], \quad i = 1, 2, \dots, 6. \quad (2)$$

因此，24 层文本主干包含 18 层 Linear Attention 和 6 层 Full Self-Attention，且每隔 4 层出现一次全注意力层。两类注意力层使用不同的投影接口：

注意力类型	层数	层位置	主要投影模块
Linear Attention	18	每个 Mixed Attention Block 的前 3 层	<code>in_proj_qkv</code> 、 <code>out_proj</code>
Full Self-Attention	6	第 4、8、12、16、20、24 层	<code>q_proj</code> 、 <code>k_proj</code> 、 <code>v_proj</code> 、 <code>o_proj</code>

Linear Attention 将 Query、Key 和 Value 的输入映射合并并在 `in_proj_qkv` 中，而 Full Self-Attention 使用彼此独立的 `q_proj`、`k_proj` 和 `v_proj`。这种异构投影结构直接决定了参数高效微调的注入方式：若仅对传统 Self-Attention 的 `q_proj`、`k_proj`、`v_proj` 和 `o_proj` 应用 LoRA，则无法覆盖占主干 75% 的 Linear Attention 层。最终配置因此同时选取 `q_proj`、`k_proj`、`v_proj`、`o_proj`、`in_proj_qkv` 和 `out_proj`，并在全部 24 层注入 LoRA，使两条注意力计算路径均可进行领域适配。

该结构还影响微调方法的兼容性。模型输入端首先连续经过三层 Linear Attention，其缓存形式和模块接口不同于标准 Self-Attention。PrefixFT 依赖的 `past_key_values` 机制无法直接适配当前线性注意力缓存；PrefixFT 与 Adapter 的实现均在该混合结构上出现未解决的兼容性问题。因此，最终训练放弃这两种方法，采用能够直接作用于上述投影矩阵的 LoRA。

2.2 项目流程

项目从课程讲义出发，依次完成数据构建、质量控制、语义增强、模型训练和效果评估：

CS201 Markdown 讲义

- > DeepSeek-V4-Flash 生成 QA
- > 长度过滤
- > BGE 问答相关性过滤与问题去重
- > Qwen-3.6-27B 质量评分
- > 五倍 QA 增强
- > Qwen3.5 参数高效微调
- > 固定测试集评估与交互式验证

该流程将原始讲义转换为结构化 QA，先通过规则、语义模型和大模型评分逐级控制数据质量，再扩大同一知识点的表达覆盖，最后使用固定测试集指标与交互式案例分析微调效果。

2.3 项目模块

项目按数据、模型、训练和评估职责划分模块：

模块或路径	功能
model/	存放实验所需的本地基础模型及相关模型文件。
QA_Gen/data/Lecture/	存放十章 CS201 Markdown 讲义，作为 QA 构建的原始知识源。
QA_Gen/QA_Gen.py	解析讲义标题层级并调用 DeepSeek-V4-Flash 生成原始 QA。
QA_Gen/QA_Filter.py	执行结构与长度过滤、BGE 相似度计算、问题去重和数据统计。
QA_Gen/QA_Scorer.py	使用 Qwen3.6-27B 对 QA 进行 0--5 分质量评分与筛选。
QA_Gen/QA_Augmentation.py	为每条原始 QA 生成四条语义等价改写，构建五倍增强语料。
Train/main.py	完成数据划分、训练、动态验证集重划分、固定测试集评估和 checkpoint 保存。
Train/config.yaml	集中配置模型路径、数据路径、训练超参数和微调方法。
Train/utils/LoRALayer.py	定义 LoRA Rank、缩放系数、Dropout、目标模块和部分层选择策略。
Train/utils/PrefixFTLayer.py	实现 Prefix Tuning，供方法兼容性实验使用。
Train/utils/AdapterFinetuningLayer.py	实现 Bottleneck Adapter，供方法兼容性实验使用。
Train/logs/	保存训练日志、测试指标与不同超参数设置的实验记录。
Eval/eval.py	加载基础模型与 LoRA 适配器，提供交互式问答和定性验证。

3. 数据集介绍

3.1 数据来源

数据来源为南方科技大学 CS201 离散数学课程十章 Markdown 讲义，位于 [QA_Gen/data/Lecture/](#)。章节主题包括：

- 1. 课程信息与概览
- 2. 逻辑与证明
- 3. 集合与函数

4. 算法复杂度
5. 数论与密码学
6. 归纳与递归
7. 计数
8. 关系
9. 图与树
10. 课程复习

3.2 QA 生成方法

每章目标生成约 1,000 条 QA，采用两种上下文粒度：

- **整章生成，占 30%：** 将整章内容作为上下文，生成 300 条跨知识点问题，类型配额为 [定义解释 100，逻辑推理 50，定义关系 100，实际应用 50]。
- **二级标题生成，占 70%：** 按 Markdown `##` 切分内容，共计划生成 700 条细粒度问题，类型配额为 [定义解释 100，逻辑推理 300，定义关系 200，实际应用 100]，再按二级标题数量整数均分。


生成模型为 DeepSeek-V4-Flash。问题生成关闭思考模式并使用 `temperature=1.2` 以增加多样性；答案生成开启高强度思考模式，此时不设置温度。提示词要求仅使用中文、不得输出多余前缀、不得引用“根据教材内容”，并排除课程成绩构成类问题。生成约 1,000 条 QA 消耗 42,616,618 tokens，其中命中缓存输入 36,071,040、未命中缓存输入 2,647,389、输出 3,898,189。

3.3 数据规模

数据处理与训练阶段的规模如下：

阶段	QA 数量	相对上一阶段	说明
原始生成数据	9,905	--	十章课程讲义生成的原始 QA。
长度过滤后	9,881	99.76% 保留	删除 24 条长度不小于 1,000 字符的 QA。
问答相关性过滤后	8,481	85.83% 保留	删除 1,400 条低相关性 QA。
问题去重后	7,431	87.62% 保留	删除 1,050 条重复问题。
质量评分过滤后	6,227	83.80% 保留	删除 1,204 条低质量 QA，最终保留率为 62.87%。
五倍增强数据	48,075	--	原始 QA 及其四条语义等价改写构成最终训练语料。
最终训练/验证池	38,460	总数据的 80%	每轮划分 33,652 训练与 4,808 验证。
固定测试集	9,615	总数据的 20%	全部 15 轮保持不变。

QA对过滤完整流程



原始数据规模略低于理论 10,000，主要原因是各二级标题配额使用整数除法，实际生成数量会随章节结构产生小幅偏差。


质量过滤数据用于分析清洗效果；最终训练所用的五倍增强语料由原始章节 QA 扩写得到，因此其规模不等于 6,227 的五倍。

3.4 数据长度特征

问题平均长度约为 40 字符，答案平均长度约为 200 字符；24 条样本的 $\max(|Q|, |A|)$ 不小于 1,000 字符。类型层面的主要特征为：

- 定义解释类通常问题短、答案较长；
- 逻辑推理类通常包含较完整的推导过程；
- 实际应用类问题和答案均为中等长度；
- 定义关系类侧重概念比较，问题较短、答案中等。

QA对长度分布统计



3.5 数据清洗步骤

3.5.1 结构与长度过滤

脚本首先验证 `question` 和 `answer` 字段是否存在且非空。实验将 1,000 字符作为超长阈值，以减少长样本对训练效率和最大序列长度的影响。当前实现允许交互式设置 QA 对、问题和答案的最大字符数。

3.5.2 BGE 问答相关性过滤

脚本使用 BGE-base-zh-v1.5 对预处理后的问题和答案编码，并计算：


$$\cos(Q, A) = \frac{\mathbf{q}^\top \mathbf{a}}{\|\mathbf{q}\|_2 \|\mathbf{a}\|_2}. \quad (4)$$

默认情况下， $\cos(Q, A) < 0.5$ 被视为问答相关性不足。该阶段过滤 1,400 条 QA，约占输入数据的 14.1%；大部分保留样本集中在 0.6--0.9 区间。

3.5.3 BGE 重复问题过滤

同一问题类型内计算两两 $\cos(Q, Q')$ 。默认情况下， $\cos(Q, Q') > 0.85$ 被视为重复，保留先出现的问题。该阶段删除 1,050 条重复问题，约占输入数据的 10.6%。该步骤需要构建相似度矩阵，时间和空间复杂度均接近 $O(n^2)$ 。

相似度分布与过滤阈值



3.5.4 Qwen 质量评分

Qwen3.6-27B 从准确性、完整性、逻辑性、表述清晰度和答案详细程度五个维度给出 0--5 整数分：

- 5：完全正确、完整清晰，可直接用于教学；
- 4：基本正确，核心信息准确，仅有轻微不足；
- 3：部分正确，有小错误但不影响核心理解；
- 2：错误较多，核心信息不准确；
- 1：完全错误或答非所问；
- 0：无效内容。

评分脚本默认批大小为 16，优先以 4-bit 量化加载评分模型，失败时回退到普通加载。过滤阈值为 $\text{score} \geq 3$ 。质量评分分析中约 75% 的样本达到保留标准；完整过滤流程在该阶段删除 1,204 条低质量 QA，最终得到 6,227 条候选数据。

3.6 数据增强

由于语义去重后的问题分布较分散，随机测试集可能包含模型训练阶段完全未见的表达方式。项目因此将每条原始 QA 扩展为五条：保留原始 QA，再由 DeepSeek-V4-Flash 生成四条含义相同但表达不同的 QA。采样实验结果如下：

数据	样本对数	平均余弦相似度	中位数	标准差	$P(\cos > 0.75)$
原始 $n = 1$	6,900	0.4148	0.4114	0.0824	0.0027
增强 $n = 5$	10,000	0.4620	0.4509	0.1065	0.0276


增强数据的平均相似度为 0.4620，高于原始数据的 0.4148，说明增强操作提高了同一知识点不同问法之间的语义密度。五倍增强调用消耗 41,949,275 tokens，其中缓存输入 20,564,352、未缓存输入 7,664,914、输出 13,720,009。

4. 模型与微调策略

4.1 模型选择

前期比较对象为 Qwen3.5-0.8B、2B 和 4B。项目选择 Qwen3.5 系列的原因是其中文生成能力、因果语言建模接口和多种尺寸选择。最终采用 2B 模型，原因是：

- 0.8B 计算成本最低，但在相近可训练参数下表达能力较弱；
- 4B 表达能力更强，但计算成本更高，并在高 Rank 下更快出现测试损失回升；
- 2B 在训练成本、容量和泛化之间形成较合理折中。



4.2 微调方法选择

项目实现了 LoRA、Prefix Tuning 和 Bottleneck Adapter。由于 Qwen3.5 混合线性注意力会改变缓存和注意力接口，PrefixFT 在当前模型上不兼容；早期 Adapter 实验也出现未解决问题。因此最终方法为 LoRA。其更新形式可写为：

$$W' = W + \frac{\alpha}{r}BA, \tag{5}$$

其中基础权重 W 冻结，仅训练低秩矩阵 A 与 B 。这种方法显著降低显存和存储开销。

4.3 训练数据格式

训练脚本将问题类型与问题拼接为用户消息：

```
问题类型: <type>
问题: <question>
```

答案作为 assistant 响应。损失仅作用于答案 token，提示部分标签设为 `-100`。最大序列长度为 1,024 tokens，超出部分截断。数据以随机种子 42 划分 70%/10%/20%；测试集固定，而训练集和验证集在每轮评估后使用不同种子重新划分。

4.4 前期参数探索

参数搜索空间包括：

- 基础模型：0.8B、2B、4B；
- LoRA Rank：4、8、16、32、64；
- $\alpha = 2r$ ；
- Dropout：[0, 0.02, 0.05, 0.1, 0.25, 0.33, 0.5]；
- 全层微调，以及输入端/输出端 24、12、6 个 Attention Block 的部分微调。

在相近可训练参数规模下，实验配置为：

基础模型	较小参数组	较大参数组
Qwen3.5-0.8B	$r = 8, 0.5407\text{M}$	$r = 16, 1.08\text{M}$
Qwen3.5-2B	$r = 8, 0.7373\text{M}$	$r = 16, 1.47\text{M}$
Qwen3.5-4B	$r = 4, 0.7864\text{M}$	$r = 8, 1.57\text{M}$


实验结果表明：基础模型越大，表达能力通常越强，但计算成本也越高。与此同时，测试曲线显示大模型和高 Rank 更容易在较早阶段过拟合，因此容量优势不能直接等同于最终泛化优势。

4.5 LoRA Rank 与过拟合

同一基础模型内，Rank 增大使训练损失下降更快，表明适配容量提高；但测试损失在达到最低点后回升更明显。过拟合指标定义为：


$$R_{\text{train/test}} = \lg \left(\frac{L_{\text{test,final}}}{L_{\text{train,final}}} \right). \tag{6}$$

该比值随可训练参数量近似指数增长。参数统计中，4B 模型从 $r = 4$ 的 786,432 个参数 (0.0187%) 增至 $r = 64$ 的 12,582,912 个参数 (0.2983%)；0.8B 模型从 270,336 (0.0359%) 增至 4,325,376 (0.5716%)。因此最终选择较低 Rank。




4.6 部分层微调

部分层实验使用 Qwen3.5-2B、 $r = 4$ 、dropout = 0，仅对输入端或输出端的 24、12、6 个注意力块注入 LoRA。Top-6 与 End-12 的结果接近，说明靠近输入端的层在相同层数预算下更有效；但无论训练损失还是测试损失，部分微调均不如全部 24 层微调。



4.7 Dropout

Dropout 实验在 Qwen3.5-2B 上比较 $r \in \{4, 8, 16\}$ 。实验观察到 $r = 8$, dropout = 0.5 的训练损失接近 $r = 4$, dropout = 0, 且高于无 Dropout 的同 Rank 模型, 说明 Dropout 有意牺牲部分拟合能力以换取更好的泛化。较高 Rank 的测试曲线过拟合更强, 因此最终使用 $r = 4$, dropout = 0.5。



4.8 最终微调设置

执行日志中的最终配置如下：


参数	设置
基础模型	Qwen3.5-2B
方法	LoRA, 因果语言建模
目标层	全部 24 层
目标模块	<code>q_proj</code> , <code>k_proj</code> , <code>v_proj</code> , <code>o_proj</code> , <code>in_proj_qkv</code> , <code>out_proj</code>
Rank / Alpha	4 / 8
缩放	标准 α/r
LoRA Dropout	0.5
初始化	Gaussian
可训练参数	1,253,376 / 1,883,078,464 (0.0666%)
Epoch	15
每设备 Batch Size	8
梯度累积	4, 单卡有效 batch 约 32
学习率	5×10^{-5}
数值精度	BF16
最大长度	1,024 tokens
数据划分	70%/10%/20%, seed 42
日志/保存	每 10 step 记录, 每 500 step 保存, 最多保留 3 个周期 checkpoint

最终训练采用 LoRA Dropout 0.5, 与 $r = 4$ 和 $\alpha = 8$ 共同构成最终参数设置。

5. 实验结果

5.1 数据增强与泛化

实验先使用与原数据量相近的增强样本比较 $n = 1$ 与 $n = 5$, 在 Qwen3.5-2B、 $r = 4$ 、 $\alpha = 8$ 、 $\text{dropout} = 0$ 下, 增强数据的测试损失最低点更低, 表明语义保持式改写有助于模型处理不同问法。进一步在完整增强集上加入 Dropout 后, 增强数据与 $\text{dropout} = 0.5$ 的组合获得最稳定的测试曲线。




5.2 最终训练指标

最终运行共完成 15,780 个优化 step，训练耗时 26,812.01 秒（约 7.45 小时），训练吞吐量为 18.827 samples/s。最终汇总指标如下：

指标	数值
最终训练损失	0.845818
最终动态验证集损失	0.773313
第 1 轮固定测试损失	0.902961
第 15 轮固定测试损失	0.840197
固定测试损失相对下降	6.95%
第 1 轮固定测试困惑度	2.466896
第 15 轮固定测试困惑度	2.316823
固定测试困惑度相对下降	6.08%
最终测试吞吐量	71.969 samples/s
总 FLOPs	1.2169×10^{18}

固定测试损失在 15 轮内持续下降，没有出现无增强实验中明显的后期反弹。这支持“增强数据加高 Dropout 缓解过拟合”的判断，但不能证明在完全独立课程问题上的泛化，因为增强版本可能被随机分配到训练集和测试集。



5.3 微调前后效果比较

实验使用同一问题比较基础模型与微调模型：

Big-O 记号中的常数 C 和 k 在证明函数上界时分别起什么作用？

5.3.1 微调前

基础模型回答冗长，并超过 512-token 输出限制。其内容包含较多铺垫和重复说明，未能以紧凑结构直接呈现两个常数的核心作用。

User> Big-O记号中的常数C和k在证明函数上界时分别起到什么作用？

Assistant> 你好！作为离散数学的助教，我很高兴为你解答这个问题。在分析算法复杂度（特别是 Big-O 表示法）的证明中， C 和 k 是定义上下界的核心概念。它们各自扮演了“控制系数”和“起始点”的角色。

为了让你更直观地理解，我们通常将 n （自变量）看作一个连续变化的正数，而 $f(n)$ 是我们要分析的函数值。

1. Constant C : 函数的缩放因子（比例尺）

核心作用：消除函数的具体数值差异，只保留增长的趋势。

在定义上界 $f(n) \leq C \cdot g(n)$ 时，常数 C 的作用是**统一量纲**。它就像是一个放大镜或缩小镜，允许我们在比较不同函数的增长速度时忽略掉那些具体的绝对数值。

* **数学表达：**

$$f(n) \leq C \cdot g(n)$$
 其中 $g(n)$ 通常是某个已知的基准函数（如 $\log n$, n^2 , $n!$ ），而 C 只是一个正实数常数。

* **实际意义：**
 即使两个函数 $f_1(n)$ 和 $f_2(n)$ 的初始斜率或截距完全不同，只要存在某个常数 C 使得对于所有足够大的 n ，不等式成立，它们的**渐近增长率就是相同的**。

* **举例：**假设 $f(n) = 5n + 3$ 和 $g(n) = n$ 。显然 $f(n)$ 比 $g(n)$ 快。我们可以找到一个很大的 C （比如 6），使得当 $n > 10$ 时， $5n + 3 \leq 6n$ 恒成立。这意味着在粗略估算时间复杂度时，我们说 $f(n)$ 的时间复杂度与 $g(n)$ 一样高（即都是 $O(n)$ ）。 C 让我们敢于忽略那 3 个常数项和 5 这个系数。

2. Constant k : 函数的起点（平移量）

核心作用：确定函数在多大 n 之后开始遵循线性规律（或幂律规律）。

在定义下界 $f(n) \geq$

5.3.2 微调后

微调后的回答显著缩短，直接说明 k 是使不等式从某一输入规模开始成立的阈值， C 是控制相对增长上界的正常数。

User> Big-O记号中的常数C和k在证明函数上界时分别起到什么作用？

Assistant> 在Big-O记号的定义中，常数C和k用于建立函数增长关系的界限。具体地，对于任意 $x > k$ ，有 $|f(x)| \leq C|g(x)|$ 成立。其中k是一个阈值，确保我们只考虑足够大的输入规模；C是一个正常数，用来量化两个函数的相对大小关系。这两个参数共同作用：通过选取一个合适的k，将待证的不等式扩展到所有大于该值的自变量，从而忽略了输入规模较小时的可能差异。例如，要证明 $n^2 + 2n < 3n^2$ 对 $n > 1$ 成立，我们可以取 $k=1$ ，并令 $C=2$ （此时当 $n \geq 1$ 时， $n^2 + 2n = n(n+2) \leq n \cdot (3n) = 3n^2$ ），即得所需不等式。

两部分结果表明，微调减少了无关铺垫，使回答更加简洁、准确，数学符号和推导结构也更加集中，体现了模型对目标课程回答风格的有效适配。为进一步保证教学场景中的可靠性，仍需通过更多题型和人工评审检验数学常数、边界条件与推导细节的一致性。

6. 结果分析

6.1 有效因素

1. **低 Rank 控制容量。** 高 Rank 显著降低训练损失，但扩大训练与测试表现差距； $r = 4$ 更适应当前数据规模。
2. **全层适配优于部分层适配。** Top-6 的单位层效率较高，但全 24 层 LoRA 的训练和测试结果更优。
3. **Dropout 提供正则化。** dropout = 0.5 明显限制训练集拟合能力，但与数据增强结合后固定测试损失持续下降。
4. **语义增强提高表达覆盖。** 五种同义问法增加了局部语义密度，使模型更容易学习同一知识点的语言不变性。
5. **参数效率较高。** 最终仅更新 0.0666% 的参数，适配器权重约 4.8 MB，明显低于全量微调成本。

6.2 项目不足与可能的改进方案

1. **数学文本预处理可能损失关键信息。** 当前相似度预处理会删除部分 LaTeX 括号内容和数学符号，可能改变公式语义。可改用保留公式结构的数学文本规范化方法，分别编码自然语言与公式，再融合两类表示进行相关性判断。
2. **问题两两去重的复杂度较高。** 完整相似度矩阵的时间和空间复杂度接近 $O(n^2)$ ，难以直接扩展到更大数据集。可使用向量数据库、近似最近邻检索或分桶聚类，仅比较候选近邻，从而将计算规模显著降低。
3. **评价指标较为单一。** 当前主要指标是交叉熵损失和定性案例，尚不能充分反映数学正确性、答案完整性和教学风格。可增加教师评分、步骤级正确率、公式一致性、答案长度、重复率及基于标准答案的语义指标。
4. **交互式系统尚缺乏知识边界控制。** 模型可能回答超出课程范围的问题或对不确定内容给出过度自信的结论。可增加课程范围检测、检索增强、置信度估计与拒答机制，提高实际教学部署中的可靠性。

6.3 结果解释

最终测试损失从 0.902961 降至 0.840197，说明在训练过程中模型对固定测试样本的答案 token 分布拟合持续改善。该现象与无增强消融中测试损失先降后升形成对比，说明增强和 Dropout 至少在当前随机划分上有效抑制了明显过拟合。然而，训练损失 0.845818 高于最终动态验证损失 0.773313 并不意味着验证集更困难或更容易，其原因包括 Dropout 仅在训练态生效、训练损失为全程平均值，以及验证集每轮重划分。最可靠的趋势证据仍是固定测试损失。

7. 实验总结

本项目完成了从课程讲义到领域助教模型的完整工程链路：基于 DeepSeek-V4-Flash 生成四类 QA，使用长度规则、BGE 语义相似度和 Qwen3.6-27B 评分进行清洗，以五倍语义改写提高问法覆盖，并在 Qwen3.5 系列上开展模型规模、LoRA Rank、部分层、Dropout 与数据增强实验。综合表达能力、计算成本和过拟合风险，最终选择 Qwen3.5-2B、全 24 层 LoRA、 $r = 4$ 、 $\alpha = 8$ 和 dropout = 0.5。

该配置以 0.0666% 的可训练参数在 48,075 条增强数据上完成 15 轮训练，固定测试损失下降 6.95%，且回答风格明显由冗长转向简洁、直接。当前成果构成了一个有效的课程领域适配原型。